

方向 C：面向动力装备的知识图谱增强检索与智能诊断 Agent ——“鸿雁计划”科创基金细化企划书 v2

汇报人：纪文龙

清华大学行健书院 2024 级本科生

2026 年 4 月

一句话概括

以 RAG（检索增强生成）为基础工具，研究三个问题：（1）工业文档检索的特殊困难怎么解决？（2）多步 Agent 推理比单轮问答好多少？（3）工业安全场景需要什么样的评估指标？——用对照实验给出量化答案，产出 1 篇 SCI 论文 + 首个中文动力设备故障诊断问答数据集。

1 核心定位：RAG 是工具，研究问题才是目标

1.1 项目的基本逻辑

在目前的开源社区支持下（LangChain、LlamaIndex、Chroma 等），搭建一个基础的 RAG 系统已经不难、不慢——这不是我们的研究贡献。

我们的研究贡献在于：在搭好 RAG 之后，围绕动力设备故障诊断这一场景，回答三个有科学价值的研究问题，并用严格的对照实验给出可量化的效果。

类比：PyTorch 是工具，不是论文。但用 PyTorch 训练模型、发现规律、解决新问题——那是论文。同理，RAG 是工具，用 RAG 回答领域内尚未解决的问题——那才是论文。

1.2 为什么这个方向“对将来帮助更大”？

- 技术栈的未来价值：**LLM/RAG/Agent 是未来 5-10 年工业 AI 的核心技术路线。掌握它比学一种具体的 CNN 架构更有长期回报。
- 技能的可迁移性：**学会构建领域知识库、设计 AI 问答评估体系，这些能力横跨所有行业——医疗、法律、制造、能源都需要。
- 个人技术优势：**Web 开发能力在系统演示和原型搭建上有直接用武之地。

2 当前技术前沿与文献空白

2.1 2024–2025 年，这个方向发生了什么？

趋势	代表性工作	对我们的启示
知识图谱增强 RAG	KBS 2025: Graph RAG 用于高铁转向架故障诊断 (DOI: 10.1016/j.knosys.2025.114855)	证明 KG+RAG+ 故障诊断可发 Q1
多 Agent 诊断系统	MAKG (2026): 多 Agent+KG 协同, 90.1% 推理准确率	多 Agent 路线已有先例
领域检索评估	PARAM (arXiv 2025): 振动数据序列化 +RAG 自动维修建议	聚焦评估和可信度是差异化方向
制造业 GraphRAG	Electronics 2025: Document GraphRAG 用于制造业 QA	Q2 级别难度可控

2.2 我们能填补什么空白？

上述已发表工作有三个共同缺陷：（1）没有针对工业文档检索的失败案例分析——都是直接报好结果，不解释”为什么通用 RAG 在工业领域不够好”；（2）没有多步 Agent 与单轮 RAG 的严格对照实验——无法量化 Agent 到底带来多大收益；（3）没有工业安全场景的专用评估指标——都用通用 NLP 指标，不考虑安全约束。

此外，中文动力设备故障诊断的问答评测数据集目前为空白。

3 三个研究问题

3.1 RQ1：工业文档检索有什么特殊困难？针对性改进能提升多少？

研究动机：我们不会凭空说”需要知识图谱增强”。而是先搭一个基础 RAG，观察它在动力设备场景中具体在哪些类型的问题上表现不好，分析原因，再针对性地提出改进方案。

预期发现的三类典型检索失败：

- 因果链断裂：用户问”汽轮机振动大怎么排查？”，基础 RAG 找到了振动相关段落，但没能把”不平衡 → 对中检查 → 动平衡”这条完整的排查链路检索出来。原因：因果关系分散在多个文档段落中。
- 跨文档推理失败：答案需要综合 3 份不同文档的信息（设备手册 + 历史案例 + 行业标准），但基础 RAG 只检索到了其中一份。
- 术语不对等：用户说”机组抢振”，文档中写的是”转子不平衡导致的强制振动”——语义相同但措辞不同，向量检索匹配不上。

针对性改进方案：

- 针对因果链断裂 → 构建故障因果知识图谱（设备 → 部件 → 故障 → 原因 → 方案），用图遍历补全因果链

- 2. 针对跨文档推理 → **三路混合检索**：向量检索 + BM25 关键词检索 + 知识图谱子图查询，结果加权融合后用 Reranker 精排
- 3. 针对术语不对等 → 构建**领域同义词表** + LLM 驱动的 **Query 改写**

实验设计：

- 对照组：基础 RAG（纯向量检索 + 固定分块）
- 实验组：改进 RAG（知识图谱 + 混合检索 + Query 改写）
- 测试集：100–200 道领域问题（事实型/诊断型/方法型三类）
- 指标：**Hit Rate@5**（前 5 个检索结果中有没有正确答案）、**MRR**（正确答案平均排在第几位）、**Chain Completeness**（新指标：检索结果是否覆盖完整的”症状 → 原因 → 方案”链条）

可衡量的效果：改进后检索准确率比基础 RAG 提升 $\geq 5\%$ （参考 KBS 2025 论文，类似改进通常在 10–20% 量级）。Chain Completeness 是我们提出的**新评估指标**，本身即为学术贡献。

3.2 RQ2：多步 Agent 推理比单轮问答好多少？

研究动机：真实的故障排查本质上是**多步信息收集 + 假设检验 + 逐步排除**的过程。一线工程师请教老师傅时，老师傅会先问”什么时候出现的？””负荷多少？”——这种**迭代式追问**是单轮 RAG 无法实现的。

Agent 工具集设计：

工具名	功能	实现方式
search_knowledge	知识库检索	RQ1 的混合检索
get_fault_chain	获取故障因果链	知识图谱子图查询
query_specs	查设备参数	结构化数据库 SQL 查询
ask_user	追问用户细节	LLM 生成追问问题
generate_diagnosis	综合诊断	LLM 推理 + 引用来源

实验设计——三级难度 × 三种系统的对照实验：

难度	问题特征	示例	预期结果
简单	单因素，答案在单篇文档中	”XX 型轴承额定温升？”	三种系统差异小
中等	需结合 2–3 个信息源	”3 号机组振动偏高的可能原因？”	Agent 小幅领先
复杂	多因素交叉、信息不完整	”异常声响 + 排气温度偏高，如何排查？”	Agent 显著领先

- **基线 A**：纯大模型直接回答（不检索）
- **基线 B**：单轮 RAG（检索一次 → 生成答案）

- 实验组 C: 多步 Agent (可检索、追问、调用工具、多轮推理)

评估方式:

- 诊断准确率 (与标准答案对比)
- 推理合理性 (邀请刘老师/课题组博士生盲评打分, 1-5 分量表)
- 按难度分层统计——**核心预期结论:** ”在复杂多因素故障场景中, 多步 Agent 的诊断准确率比单轮 RAG 提升 $Y\%$ ”

3.3 RQ3: 工业安全场景需要什么样的评估指标?

研究动机: 现有 RAG 评估框架 (RAGAS 等) 只关注 ”答案和文档是否一致”, 不关注工业安全约束。但在动力设备领域, 一个 ”看似合理但参数错误” 的回答可能导致安全事故。通用指标无法捕捉这类风险。

具体研究步骤:

1. **发现问题:** 用通用 RAGAS 指标 (Faithfulness、Answer Relevancy) 评估系统, 同时请领域专家评分。对比两者结果, 找出 ”RAGAS 给高分但专家说不对” 的案例——这些案例揭示了通用指标在工业领域的盲点。
2. **提出补充指标:**
 - **参数一致性:** 回答中引用的数值 (温度、转速、压力等) 是否与知识库中的记录一致
 - **因果逻辑一致性:** 诊断链条的 ”原因 $\rightarrow$ 结果” 是否符合知识图谱中的因果关系
 - **安全拒答率:** 面对超出知识范围的问题, 系统正确拒绝回答 (而非编造) 的比例
3. **验证指标有效性:** 以专家评分为 ground truth, 计算我们的指标与专家评分的 **Spearman** 相关系数, 并与 RAGAS 的通用指标对比。

可衡量的效果: 预期结论—— ”我们提出的工业领域评估指标与专家评分的相关系数为 $r_s \approx 0.85$, 而通用 RAGAS 指标仅为 $r_s \approx 0.60$ ”。

4 论文贡献总结

#	贡献内容	贡献类型	创新程度
1	系统分析工业文档检索的三类特殊困难，提出图谱增强的混合检索策略并验证有效性	方法 + 实验	中-高
2	多步 Agent 诊断推理 vs 单轮 RAG 的严格对照实验，按难度分层量化 Agent 的改进幅度	实验	中
3	提出 Chain Completeness、参数一致性、安全拒答率等领域特定评估指标，验证其优于通用指标	指标/方法论	高
4	构建首个中文动力设备故障诊断问答评测数据集（200+ 问答对，含三种难度、三种类型）	数据集/资源	很高

发表定位：投向 *Expert Systems with Applications* (IF~8.5) 或 *Knowledge-Based Systems* (IF~8.1)。这两个 Q1 期刊在 2024-2025 年大量接收 KG+RAG+ 工业应用类论文（如 KBS 2025 已发表“Graph RAG for Train Bogies”同类工作）。

保底策略：即使 RQ2/RQ3 做得不够深，仅凭贡献 1（检索改进实验）+ 贡献 4（中文 Benchmark），也足以投 *Applied Sciences* 或 *Electronics*（Q2）。

5 预期成果

- 1 篇 SCI 论文：Q1 期刊（KBS/ESWA）为目标，Q2 为保底。
- 1 个评测数据集：首个中文动力设备故障诊断 QA Benchmark（200+ 问答对），按学术规范标准化后开源，可供后续研究者使用。
- 1 套演示系统：Web 界面的对话式诊断助手——输入故障描述，输出带引用来源的诊断建议 + Agent 推理过程可视化。
- 鸿雁计划结题：完整结题报告 + 上述成果。

6 W1–W30 逐周工作计划

每周投入 8 小时，分 6 阶段。整体逻辑：搭工具（快速）→ 发现问题 → 设计方案 → 对照实验 → 写论文。

6.1 阶段一：技术调研 + 快速搭建基础 RAG（W1-W5，4 月）

阶段目标：搞懂前沿、跑通工具链、得到一个”能用但不完美”的基础 RAG——它的不完美恰好是后续研究的起点。

- W1 文献精读。**精读 5 篇核心论文：(1) KBS 2025 Graph RAG for Train Bogies；(2) PARAM 框架（arXiv 2025）；(3) MAKG 多 Agent 框架（2026）；(4) RAG 最新综述；(5) 刘老师课题组的故障诊断代表论文。输出：2 页技术调研摘要发刘老师。
- W2 数据盘点与收集。**与课题组博士生沟通，梳理可用文档（技术手册、故障案例库、行业标准、论文）。整理一份”知识资源清单”，明确数据量和格式。同时下载公开国标/行标作为补充。
- W3 搭建基础 RAG。**用 LangChain + Chroma 向量数据库 + Qwen 大模型（或开源替代），跑通完整 Pipeline：文档加载 → 分块 → Embedding → 存储 → 检索 → 生成回答。先导入 20 份文档做验证。
- W4 导入全部数据。**文档预处理 Pipeline 开发（PDF/Word → 文本 → 清洗 → 分块 → 标注元数据）。目标：处理全部可用文档（预计 100-500 份）。
- W5 基础 RAG 效果摸底。**编写 50 道领域测试问题，跑一轮基础 RAG，手动分析失败案例——记录”问了什么””检索到了什么””哪里不对”。这些失败案例就是 RQ1 的出发点。输出：基础 RAG 效果报告，发刘老师确认下一步。

6.2 阶段二：构建评测数据集 + 知识图谱（W6-W10，5-6 月）

阶段目标：建成中文 QA 评测数据集（论文贡献 4）和故障因果知识图谱（为 RQ1 服务）。

- W6 设计评测数据集。**定义题目分类体系：按难度（简单/中等/复杂）× 类型（事实型/诊断型/方法型），每类至少 30 题。编写标注指南，确保每道题包含：问题、标准答案、引用来源、难度标签、类型标签。
- W7 编写评测数据集（上）。**从故障案例和论文中提取 100 道问题。每道题人工编写标准答案和引用来源。
- W8 编写评测数据集（下）。**再编写 100 道，完成 200+ 题目。部分题目请课题组博士生校验。
- W9 构建故障因果知识图谱。**定义本体（设备类型 → 部件 → 故障模式 → 原因 → 症状 → 维修方案）。用 LLM 从文档中半自动抽取三元组，人工校验正确性。存入 Neo4j 或 NetworkX。
- W10 阶段验证 + 汇报。**用评测数据集正式测试基础 RAG，记录各项指标。把结果和知识图谱构建情况发刘老师。

6.3 阶段三：核心研发——RQ1 检索改进 + RQ2 Agent 搭建（W11-W15，7 月）

这是最关键的阶段：实现创新方案，初步验证有效性。

- W11 实现混合检索。**(1) BM25 关键词检索 (Elasticsearch 或 rank_bm25 库); (2) 知识图谱子图查询——用户 Query 经 LLM 抽取实体后查图谱关联节点; (3) 三路结果加权融合 + Reranker 精排 (bge-reranker 模型)。
- W12 实现 Query 改写与同义词表。**用 LLM 将短问题扩展为详细检索 Query; 构建领域同义词映射表 (如“抢振”→“转子不平衡导致的强制振动”)。在评测数据集上测试改进效果。
- W13 搭建多步 Agent 框架。**基于 LangGraph 实现 ReAct 模式 Agent: Reasoning (思考) → Action (调用工具) → Observation (观察结果) 循环。定义 5 个工具 (见 RQ2 工具表)。在 10 道复杂题上手动调试。
- W14 Agent 策略设计。**设计追问逻辑 (信息不足时主动求证)、置信度判断逻辑 (低置信时标注“仅供参考”)、安全兜底逻辑 (涉及危险操作时附加警告)。
- W15 初步验证 + 向刘老师汇报。**改进 RAG vs 基础 RAG 的初步对比; Agent vs 单轮 RAG 的初步对比。写中期报告。

6.4 阶段四：大规模对照实验——出论文数据 (W16-W20, 8-9 月)

阶段目标：用严格的对照实验回答 RQ1-RQ3，产出论文所需的全部数据和图表。

- W16 RQ1 完整实验。**基础 RAG vs 改进 RAG，在 200+ 题评测集上跑完整对比。记录 Hit Rate@5、MRR、Chain Completeness。做消融实验：去掉 KG / 去掉 BM25 / 去掉 Reranker，分别看效果变化。
- W17 RQ2 完整实验。**纯 LLM vs 单轮 RAG vs 多步 Agent，三种系统 × 三级难度 = 9 组实验。每组在对应难度的测试题上跑，记录准确率。
- W18 RQ2 专家评估。**邀请刘老师和 2-3 位博士生，对 50 道复杂诊断题的回答做盲评打分 (1-5 分：准确性、完整性、推理合理性)。计算评分者间一致性 (Cohen's Kappa)。
- W19 RQ3 评估指标实验。**(1) 用 RAGAS 评分 + 我们的三个指标同时评估系统; (2) 以专家评分为 ground truth; (3) 计算每种指标与专家评分的 Spearman 相关系数。
- W20 结果整理。**汇总全部实验数据，画论文图表：检索对比柱状图、Agent 推理流程 Case Study、评估指标相关系数对比图、数据集统计信息表。

6.5 阶段五：写论文 + 搭演示系统 (W21-W25, 10-11 月)

- W21 搭 Web 演示界面。**用 Streamlit 或 Gradio：左侧输入故障描述、右侧显示诊断回答 (含引用来源链接)，底部展示 Agent 的推理过程 (检索了什么、调用了什么工具、为什么追问)。
- W22 和刘老师确认论文结构和目标期刊；**写第 1 章 (动力设备智能运维背景、现有 RAG 在工业场景的不足、我们的研究问题)。
- W23 第 2 章 (相关工作：RAG 技术、知识图谱、Agent 框架在工业领域的应用现状)，**重点对比 KBS 2025 和 PARAM。

W24 第 3 章（系统设计：基础 RAG → 失败分析 → 改进方案，包含混合检索架构图、Agent 工具链图、评估指标定义）。

W25 第 4 章（实验结果：RQ1/RQ2/RQ3 的全部对比表、消融分析、Case Study、专家评估结果）。

6.6 阶段六：投稿 + 结题（W26-W30, 12-1 月）

W26 第 5 章（结论、局限性、未来工作）+ 全文润色。整理评测数据集，准备开源（GitHub + 数据说明文档）。

W27 给刘老师审改，根据反馈补充实验或修改论述。

W28 按目标期刊模板排版，提交投稿。

W29 写鸿雁计划结题报告（约 15 页）。

W30 提交结题材料包，项目完成。