

方向 C：工业故障诊断中的检索增强生成

——新框架、新指标与首个中文评测基准

——“鸿雁计划” 科创基金细化企划书 v3

汇报人：纪文龙

清华大学行健书院 2024 级本科生

2026 年 4 月

一句话概括

针对通用 RAG 在工业文档检索中的三类特殊失败模式（因果链断裂、跨文档推理失败、术语不对等），提出知识图谱增强的三路混合检索框架与两个原创评估指标（Chain Completeness、Industrial Faithfulness Score），并构建首个中文动力设备故障诊断问答评测数据集。通过三组严格对照实验量化各项改进幅度，产出 1 篇 SCI 论文（目标 Q1）。

1 核心定位：RAG 是工具，研究问题才是目标

1.1 项目的基本逻辑

在目前的开源社区支持下（LangChain、LlamaIndex、Chroma 等），搭建一个基础的 RAG 系统已经不难、不慢——这不是我们的研究贡献。

我们的研究贡献在于：在搭好 RAG 之后，围绕动力设备故障诊断这一场景，回答三个有科学价值的研究问题，并用严格的对照实验给出可量化的效果。

类比：PyTorch 是工具，不是论文。但用 PyTorch 训练模型、发现规律、解决新问题——那是论文。同理，RAG 是工具，用 RAG 回答领域内尚未解决的问题——那才是论文。

本研究的论文故事线：

通用 RAG 在工业领域的失败模式）→ 提出方案（新框架 + 新指标）→ 实验验证（三组对照实验）→ 贡献资源（首个中文 E

1.2 为什么这个方向“对将来帮助更大”？

- 技术栈的未来价值：**LLM/RAG/Agent 是未来 5-10 年工业 AI 的核心技术路线。掌握它比学一种具体的 CNN 架构更有长期回报。
- 技能的可迁移性：**学会构建领域知识库、设计 AI 问答评估体系，这些能力横跨所有行业——医疗、法律、制造、能源都需要。
- 个人技术优势：**Web 开发能力在系统演示和原型搭建上有直接用武之地。

2 当前技术前沿与文献空白

2.1 2024–2025 年，这个方向发生了什么？

趋势	代表性工作	对我们的启示
知识图谱增强 RAG	KBS 2025: Graph RAG 用于高铁转向架故障诊断 (DOI: 10.1016/j.knosys.2025.114855)	证明 KG+RAG+ 故障诊断可发 Q1
多 Agent 诊断系统	MAKG (2026): 多 Agent+KG 协同, 90.1% 推理准确率	多 Agent 路线已有先例
领域检索评估	PARAM (arXiv 2025): 振动数据序列化 +RAG 自动维修建议	聚焦评估和可信度是差异化方向
制造业 GraphRAG	Electronics 2025: Document GraphRAG 用于制造业 QA	Q2 级别难度可控

2.2 我们能填补什么空白？

上述已发表工作有三个共同缺陷：（1）没有针对工业文档检索的失败案例分析——都是直接报好结果，不解释“为什么通用 RAG 在工业领域不够好”；（2）没有多步 Agent 与单轮 RAG 的严格对照实验——无法量化 Agent 到底带来多大收益；（3）没有工业安全场景的专用评估指标——都用通用 NLP 指标，不考虑安全约束。

此外，中文动力设备故障诊断的问答评测数据集目前为空白。

2.3 与已发表直接可比论文的差异化对比

下表从五个关键维度，逐一说明本研究相比三篇已发表/已接收的直接可比论文具体多做了什么：

对比维度	KBS 2025 高铁转向架	Electronics 2025 制造业文档 QA	MAKG 2026 工业维护	本研究
检索策略	KG 增强	KG 增强	多 Agent 分工	KG+BM25+ 向量三路混合 +Reranker
多步推理 Agent	✗	✗	✓（无对照）	✓+ 三级难度对照实验
评估指标	通用 NLP 指标	通用 NLP 指标	通用 NLP 指标	IFS + Chain Completeness （原创）
中文 Benchmark	✗	✗	✗	✓ 首个（200+ 问答对）
安全约束考量	✗	✗	✗	✓ 安全拒答率

表 1: 与三篇直接可比论文的系统性对比。KBS 2025 = Knowledge-Based Systems, Vol.331; Electronics 2025 = Electronics, Vol.14(11); MAKG = 多 Agent 知识图谱框架（2026 预印本）。

关键结论：与发在 KBS（Q1, IF≈8.1）上的最新同类工作相比，本研究在**多步推理对照实验**、**原创评估指标**、**中文 Benchmark**、**安全约束**四个维度均有明确的增量贡献。若一篇只做了“KG 增强检索”的工作可以发 Q1，我们的方案发 Q1 是完全合理的预期。

3 三个研究问题

3.1 RQ1：工业文档检索有什么特殊困难？针对性改进能提升多少？

研究动机：我们不会凭空说“需要知识图谱增强”。而是先搭一个基础 RAG，观察它在动力设备场景中具体在哪些类型的问题上表现不好，分析原因，再针对性地提出改进方案。这符合科学研究的基本逻辑：**观察 → 假设 → 实验 → 结论**。

预期发现的三类典型检索失败：

- **因果链断裂：**用户问“汽轮机振动大怎么排查？”，基础 RAG 找到了振动相关段落，但没能把“不平衡 → 对中检查 → 动平衡”这条完整的排查链路检索出来。原因：因果关系分散在多个文档段落中。
- **跨文档推理失败：**答案需要综合 3 份不同文档的信息（设备手册 + 历史案例 + 行业标准），但基础 RAG 只检索到了其中一份。
- **术语不对等：**用户说“机组抢振”，文档中写的是“转子不平衡导致的强制振动”——语义相同但措辞不同，向量检索匹配不上。

针对性改进方案：

1. 针对因果链断裂 → 构建故障因果知识图谱（设备 → 部件 → 故障 → 原因 → 方案），用图遍历补全因果链
2. 针对跨文档推理 → 三路混合检索：向量检索 + BM25 关键词检索 + 知识图谱子图查询，结果加权融合后用 Reranker 精排
3. 针对术语不对等 → 构建领域同义词表 + LLM 驱动的 Query 改写

实验设计：

- 对照组：基础 RAG（纯向量检索 + 固定分块）
- 实验组：改进 RAG（知识图谱 + 混合检索 + Query 改写）
- 测试集：100–200 道领域问题（事实型/诊断型/方法型三类）
- 指标：Hit Rate@5、MRR、以及我们提出的原创指标 Chain Completeness

原创指标：Chain Completeness (CC)

动机：传统检索评估指标（Hit Rate、MRR）只衡量“答案文档有没有被找到”，但不关心检索结果是否覆盖了完整的诊断推理链。在故障诊断中，仅找到“振动大”的文档是不够的，还需要找到“不平衡 → 对中 → 动平衡”的完整排查路径。现有指标无法衡量这一维度。

定义：给定一个诊断问题 q ，其标准答案包含一条因果链 $S_{\text{gold}}(q) = \{s_1, s_2, \dots, s_n\}$ （例如“症状 → 可能原因 → 排查步骤 → 修复方案”各环节）。检索系统返回文档集 $D_{\text{ret}}(q)$ 。Chain Completeness 定义为：

$$CC(q) = \frac{|\{s_i \in S_{\text{gold}}(q) \mid \exists d_j \in D_{\text{ret}}(q), s_i \sqsubseteq d_j\}|}{|S_{\text{gold}}(q)|}$$

其中 $s_i \sqsubseteq d_j$ 表示因果链步骤 s_i 的语义被文档 d_j 覆盖（通过 NLI 模型或人工判断确定）。

系统级指标： $\overline{CC} = \frac{1}{|Q|} \sum_{q \in Q} CC(q)$ ，即测试集上所有问题的平均 Chain Completeness。

为什么是创新贡献：这是首个专门衡量“检索结果是否覆盖完整诊断推理链”的评估指标，填补了 RAG 评估在工业故障诊断场景中的空白。

可衡量的效果：改进后检索准确率比基础 RAG 提升 $\geq 5\%$ （参考 KBS 2025 论文，类似改进通常在 10–20% 量级）。Chain Completeness 的提升幅度预期更大，因为基础 RAG 在因果链覆盖上存在系统性缺陷。

3.2 RQ2：多步 Agent 推理比单轮问答好多少？

研究动机：真实的故障排查本质上是多步信息收集 + 假设检验 + 逐步排除的过程。一线工程师请教老师傅时，老师傅会先问“什么时候出现的？”“负荷多少？”——这种迭代式追问是单轮 RAG 无法实现的。我们的核心问题不是“能不能搭 Agent”（工程问题），而是“Agent 比不用 Agent 好多少”（研究问题）。

Agent 工具集设计：

工具名	功能	实现方式
search_knowledge	知识库检索	RQ1 的混合检索
get_fault_chain	获取故障因果链	知识图谱子图查询
query_specs	查设备参数	结构化数据库 SQL 查询
ask_user	追问用户细节	LLM 生成追问问题
generate_diagnosis	综合诊断	LLM 推理 + 引用来源

实验设计——三级难度 × 三种系统的对照实验：

难度	问题特征	示例	预期结果
简单	单因素，答案在单篇文档中	“XX 型轴承额定温升？”	三种系统差异小
中等	需结合 2-3 个信息源	“3 号机组振动偏高的可能原因？”	Agent 小幅领先
复杂	多因素交叉、信息不完整	“异常声响 + 排气温度偏高，如何排查？”	Agent 显著领先

- **基线 A：**纯大模型直接回答（不检索）
- **基线 B：**单轮 RAG（检索一次 → 生成答案）
- **实验组 C：**多步 Agent（可检索、追问、调用工具、多轮推理）

评估方式：

- 诊断准确率（与标准答案对比）
- 推理合理性（邀请刘老师/课题组博士生盲评打分，1-5 分量表）
- 按难度分层统计——**核心预期结论：**“在复杂多因素故障场景中，多步 Agent 的诊断准确率比单轮 RAG 提升 Y%”
- 计算评分者间一致性（Cohen’s Kappa），确保专家评估的可靠性

3.3 RQ3：工业安全场景需要什么样的评估指标？

研究动机：现有 RAG 评估框架（RAGAS 等）只关注“答案和文档是否一致”，不关注**工业安全约束**。但在动力设备领域，一个“看似合理但参数错误”的回答可能导致安全事故。通用指标无法捕捉这类风险。

具体研究步骤：

1. **发现问题：**用通用 RAGAS 指标（Faithfulness、Answer Relevancy）评估系统，同时请领域专家评分。对比两者结果，找出“**RAGAS 给高分但专家说不对**”的案例——这些案例揭示了通用指标在工业领域的盲点。
2. **提出新指标——Industrial Faithfulness Score (IFS)：**

3. 验证指标有效性：以专家评分为 ground truth，计算 IFS 与专家评分的 **Spearman** 相关系数，并与 RAGAS 的通用指标对比。

原创指标：Industrial Faithfulness Score (IFS)

动机：通用忠实度指标（如 RAGAS Faithfulness）仅检查“回答是否基于检索文档”，但不检查参数是否正确、因果逻辑是否成立、超出知识范围时是否安全拒答。在安全攸关的工业场景中，这三类错误的后果远比一般 NLP 任务严重。

定义：给定系统对问题 q 的回答 a ，Industrial Faithfulness Score 定义为三个子维度的加权组合：

$$\text{IFS}(a, q) = \alpha \cdot \text{ParamAcc}(a) + \beta \cdot \text{CausalAlign}(a) + \gamma \cdot \text{SafeRef}(a, q)$$

三个子维度分别为：

- **参数一致性 ParamAcc(a)**：回答中引用的数值参数（温度、转速、压力等）与知识库记录的匹配比例。

$$\text{ParamAcc}(a) = \frac{|\{\text{回答中的参数值}\} \cap \{\text{知识库中的正确值}\}|}{|\{\text{回答中的参数值}\}|}$$

- **因果逻辑一致性 CausalAlign(a)**：诊断链条中的“原因 $\rightarrow$ 结果”关系是否与知识图谱中的因果边一致。

$$\text{CausalAlign}(a) = \frac{|\{\text{回答中的因果对}\} \cap \{\text{图谱中的因果边}\}|}{|\{\text{回答中的因果对}\}|}$$

- **安全拒答 SafeRef(a, q)**：面对超出知识范围的问题，系统正确拒绝回答（而非编造）的指示函数。

$$\text{SafeRef}(a, q) = \begin{cases} 1, & \text{若 } q \notin \text{知识范围 且 系统正确拒答} \\ 1, & \text{若 } q \in \text{知识范围 且 系统正常作答} \\ 0, & \text{其他（编造或遗漏）} \end{cases}$$

权重 α, β, γ 通过与专家评分的多元回归分析确定，使 IFS 与专家判断的相关性最大化。

为什么是创新贡献：这是首个面向安全攸关工业场景的 RAG 忠实度量化指标，将通用的“是否基于文档”扩展为“参数是否正确、逻辑是否成立、不确定时是否安全拒答”三个维度，填补了工业垂直领域幻觉检测的空白。

可衡量的效果：预期结论——“IFS 与专家评分的 Spearman 相关系数为 $r_s \approx 0.85$ ，而通用 RAGAS Faithfulness 指标仅为 $r_s \approx 0.60$ ”。

4 论文贡献总结

#	贡献内容	贡献类型	创新度	已有工作未覆盖
1	系统分析工业文档检索的三类特殊困难，提出图谱增强三路混合检索策略并验证有效性	方法 + 实验	中-高	KBS 2025 仅用 KG 增强，未做失败案例分析和三路融合
2	提出 Chain Completeness 指标：首个衡量检索结果对诊断因果链覆盖度的评估指标	指标/方法论	高	所有已有工作均使用通用检索指标
3	多步 Agent vs 单轮 RAG 的三级难度对照实验，量化 Agent 在复杂场景中的改进幅度	实验	中	MAKG 有多 Agent 但无对照实验
4	提出 IFS 指标：首个面向安全攸关工业场景的 RAG 忠实度量化方法	指标/方法论	高	所有已有工作均无安全约束评估
5	构建首个中文动力设备故障诊断问答评测数据集（200+ 问答对，三种难度 × 三种类型）	数据集/资源	很高	目前完全空白

发表目标：投向 *Expert Systems with Applications* (IF~8.5) 或 *Knowledge-Based Systems* (IF~8.1)。这两个 Q1 期刊在 2024–2025 年大量接收 KG+RAG+ 工业应用类论文（如 KBS 2025 已发表 “Graph RAG for Train Bogies” 同类工作），明确接受系统论文和数据集贡献论文。
双轨策略：

- 冲击 Q1 (KBS / ESWA)：五项贡献齐备，重点突出 IFS 新指标和 Benchmark 数据集
- 稳拿 Q2 (Applied Sciences / Electronics)：即使 RQ2/RQ3 做得不够深，仅凭贡献 1（检索改进实验）+ 贡献 5（中文 Benchmark）已足够

5 预期成果

- 1 篇 SCI 论文：冲击 Q1 (KBS/ESWA)，保底 Q2 (Applied Sciences/Electronics)。
- 2 个原创评估指标：Chain Completeness（检索因果链覆盖度）和 IFS（工业忠实度评分），可供后续研究者在工业 RAG 领域复用。
- 1 个评测数据集：首个中文动力设备故障诊断 QA Benchmark（200+ 问答对），按学术规范标准化后开源，预期成为本研究最具长期引用价值的产出。
- 1 套演示系统：Web 界面的对话式诊断助手——输入故障描述，输出带引用来源的诊断建议 +

Agent 推理过程可视化。

- 鸿雁计划结题：完整结题报告 + 上述成果。

6 风险评估与缓解策略

风险	概率	缓解策略
审稿人质疑“搭了个系统，没有方法创新”	中	靠两个原创指标（CC 和 IFS）和首个中文 Benchmark 对冲——数据集贡献和指标贡献是审稿人无法否认的学术增量
实验中 KG 增强检索无显著提升	低	在故障诊断这种高度结构化的知识领域，KG 检索几乎必然优于纯向量检索（已有 KBS 2025 等多篇论文实证）
课题组可用文档数据不足	中	可用公开国标/行标（GB/T 系列）+ 设备技术手册 + 刘老师课题组已发论文作为替代数据源
研究期间被同领域论文抢先发表	低	中文 + 动力设备（汽轮机/发电机）+ 知识图谱这一交叉点极窄，竞争者很少

7 W1–W30 逐周工作计划

每周投入 8 小时，分 6 阶段。整体逻辑：搭工具（快速）→ 发现问题 → 设计方案 → 对照实验 → 写论文。

7.1 阶段一：技术调研 + 快速搭建基础 RAG（W1–W5，4 月）

阶段目标：搞懂前沿、跑通工具链、得到一个“能用但不完美”的基础 RAG——它的不完美恰好是后续研究的起点。

阶段里程碑：基础 RAG 效果摸底报告 → 发刘老师确认

- W1** 文献精读。精读 5 篇核心论文：(1) KBS 2025 Graph RAG for Train Bogies；(2) PARAM 框架（arXiv 2025）；(3) MAKG 多 Agent 框架（2026）；(4) RAG 最新综述；(5) 刘老师课题组的故障诊断代表论文。输出：2 页技术调研摘要发刘老师。
- W2** 数据盘点与收集。与课题组博士生沟通，梳理可用文档（技术手册、故障案例库、行业标准、论文）。整理一份“知识资源清单”，明确数据量和格式。同时下载公开国标/行标作为补充。
- W3** 搭建基础 RAG。用 LangChain + Chroma 向量数据库 + Qwen 大模型（或开源替代），跑通完整 Pipeline：文档加载 → 分块 → Embedding → 存储 → 检索 → 生成回答。先导入 20 份文档做验证。
- W4** 导入全部数据。文档预处理 Pipeline 开发（PDF/Word → 文本 → 清洗 → 分块 → 标注元数据）。目标：处理全部可用文档（预计 100–500 份）。

W5 基础 RAG 效果摸底。编写 50 道领域测试问题，跑一轮基础 RAG，手动分析失败案例——记录“问了什么””检索到了什么””哪里不对”。这些失败案例就是 RQ1 的出发点。输出：基础 RAG 效果报告，发刘老师确认下一步。

7.2 阶段二：构建评测数据集 + 知识图谱（W6-W10，5-6 月）

阶段目标：建成中文 QA 评测数据集（论文贡献 5）和故障因果知识图谱（为 RQ1 服务）。

阶段里程碑：**200+ 题评测数据集 + 知识图谱初版** → 发刘老师评审

W6 设计评测数据集。定义题目分类体系：按难度（简单/中等/复杂）× 类型（事实型/诊断型/方法型），每类至少 30 题。编写标注指南，确保每道题包含：问题、标准答案、引用来源、难度标签、类型标签。

W7 编写评测数据集（上）。从故障案例和论文中提取 100 道问题。每道题人工编写标准答案和引用来源。

W8 编写评测数据集（下）。再编写 100 道，完成 200+ 题目。部分题目请课题组博士生校验。

W9 构建故障因果知识图谱。定义本体（设备类型 → 部件 → 故障模式 → 原因 → 症状 → 维修方案）。用 LLM 从文档中半自动抽取三元组，人工校验正确性。存入 Neo4j 或 NetworkX。

W10 阶段验证 + 汇报。用评测数据集正式测试基础 RAG，记录各项指标。把结果和知识图谱构建情况发刘老师。

7.3 阶段三：核心研发——RQ1 检索改进 + RQ2 Agent 搭建（W11-W15，7 月）

这是最关键的阶段：实现创新方案，初步验证有效性。

阶段里程碑：**中期报告——检索改进 + Agent 初步对比结果** → 发刘老师

W11 实现混合检索。(1) BM25 关键词检索（Elasticsearch 或 rank_bm25 库）；(2) 知识图谱子图查询——用户 Query 经 LLM 抽取实体后查图谱关联节点；(3) 三路结果加权融合 + Reranker 精排（bge-reranker 模型）。

W12 实现 Query 改写与同义词表。用 LLM 将短问题扩展为详细检索 Query；构建领域同义词映射表（如“抢振”→“转子不平衡导致的强制振动”）。在评测数据集上测试改进效果。

W13 搭建多步 Agent 框架。基于 LangGraph 实现 ReAct 模式 Agent：Reasoning（思考）→ Action（调用工具）→ Observation（观察结果）循环。定义 5 个工具（见 RQ2 工具表）。在 10 道复杂题上手动调试。

W14 Agent 策略设计。设计追问逻辑（信息不足时主动求证）、置信度判断逻辑（低置信时标注“仅供参考”）、安全兜底逻辑（涉及危险操作时附加警告）。

W15 初步验证 + 向刘老师汇报。改进 RAG vs 基础 RAG 的初步对比；Agent vs 单轮 RAG 的初步对比。写中期报告。

7.4 阶段四：大规模对照实验——出论文数据（W16-W20, 8-9 月）

阶段目标：用严格的对照实验回答 RQ1-RQ3，产出论文所需的全部数据和图表。

阶段里程碑：三组 RQ 的完整实验数据 + 论文图表初稿

W16 RQ1 完整实验。基础 RAG vs 改进 RAG，在 200+ 题评测集上跑完整对比。记录 Hit Rate@5、MRR、Chain Completeness。做消融实验：去掉 KG / 去掉 BM25 / 去掉 Reranker，分别看效果变化。

W17 RQ2 完整实验。纯 LLM vs 单轮 RAG vs 多步 Agent，三种系统 × 三级难度 = 9 组实验。每组在对应难度的测试题上跑，记录准确率。

W18 RQ2 专家评估。邀请刘老师和 2-3 位博士生，对 50 道复杂诊断题的回答做盲评打分（1-5 分：准确性、完整性、推理合理性）。计算评分者间一致性（Cohen's Kappa）。

W19 RQ3 评估指标实验。(1) 用 RAGAS 评分 + IFS 同时评估系统；(2) 以专家评分为 ground truth；(3) 计算每种指标与专家评分的 Spearman 相关系数。

W20 结果整理。汇总全部实验数据，画论文图表：检索对比柱状图、Agent 推理流程 Case Study、IFS 与 RAGAS 相关系数对比图、数据集统计信息表。

7.5 阶段五：写论文 + 搭演示系统（W21-W25, 10-11 月）

阶段里程碑：论文初稿 + 可演示的 Web 系统

W21 搭 Web 演示界面。用 Streamlit 或 Gradio：左侧输入故障描述、右侧显示诊断回答（含引用来源链接），底部展示 Agent 的推理过程（检索了什么、调用了什么工具、为什么追问）。

W22 和刘老师确认论文结构和目标期刊；写第 1 章（动力设备智能运维背景、现有 RAG 在工业场景的不足、我们的研究问题）。

W23 第 2 章（相关工作：RAG 技术、知识图谱、Agent 框架在工业领域的应用现状），重点对比 KBS 2025 和 MAKG。

W24 第 3 章（系统设计：基础 RAG → 失败分析 → 改进方案，包含混合检索架构图、Agent 工具链图、CC 和 IFS 指标的形式化定义）。

W25 第 4 章（实验结果：RQ1/RQ2/RQ3 的全部对比表、消融分析、Case Study、专家评估结果）。

7.6 阶段六：投稿 + 结题（W26-W30, 12-1 月）

阶段里程碑：论文投稿 + 鸿雁计划结题

W26 第 5 章（结论、局限性、未来工作）+ 全文润色。整理评测数据集，准备开源（GitHub + 数据说明文档）。

W27 给刘老师审改，根据反馈补充实验或修改论述。

W28 按目标期刊模板排版，提交投稿。

W29 写鸿雁计划结题报告（约 15 页）。

W30 提交结题材料包，项目完成。