

第一阶段进展汇报

向量化存储Pipeline全流程跑通

纪文龙

2026-04-10

jiwenlong/vectorize-pipeline

246

标注文本块

21

向量化 Chunk

1024

向量维度

5/5

检索测试通过



✓ 全部 4 个步骤已完成 详见运行结果.txt

❌ 问题 1：极短文本碎片

OCR 标注时 bbox 切割过细，
导致 7 个文本块不足 5 个字符：

" 程体系。" " 建方法" " 印证。"

占比 2.8%，影响检索匹配准确率

根因：双栏 PDF 的 bbox 跨列切断

❌ 问题 2：双栏文本交叉

按纵坐标排序时，左右栏重叠

导致 chunk 内容不连贯：

左栏第 3 行 → 右栏第 1 行 → 左栏第 4 行

影响严重：LLM 无法理解上下文

根因：排序未区分 x 坐标（栏位）

💡 改进方案

1. 加入 x 坐标区分左右栏
2. 合并极短块到相邻段落
3. 反馈给郭老师优化标注

本周



✅ 已全部完成

✓ Pipeline 跑通 ✓ 数据质量分析 ✓ 向量化存储 ✓ 代码推送 GitLab ✓ 汇报材料

2-4 周



➔ 中期任务

P0: 全量 1000 本手册跑 Pipeline
P1: BM25 关键词检索（混合检索）
P1: LangGraph 问答流程搭建
P2: 接入智谱/千问 API

暑假前



🧑‍🔬 研究性任务（独立负责）

故障因果知识图谱构建（Graph RAG）
多步 Agent 推理框架（LangGraph）
中文 QA 评测数据集 + 对照实验
目标：1 篇 SCI 论文（6-7 月）